

Explainable AI - metody wyjaśnialności w analizie kompleksów ligand-receptor

Jakub Gołąb, Dorian Rząsa, Palina Posakh, Yury Sarosek
Jagiellonian University

June 19, 2026

Cel projektu

- **Analiza kompleksów ligand–receptor** reprezentowanych w postaci fingerprintów oddziaływań strukturalnych oraz wykorzystanie metod uczenia maszynowego do określenia korelacji pomiędzy konkretnymi zestawami oddziaływań a aktywnością,
- **Zastosowanie metod wyjaśnialności** w celu identyfikacji oddziaływań z aminokwasami kluczowych dla aktywności oraz porównanie wyników uzyskanych różnymi metodami wyjaśnialności z wynikami analizy statystycznej,
- **Porównanie aminokwasów** wskazywanych jako istotne na odpowiadających sobie pozycjach w sekwencji spokrewnionych receptorów.

Dane - receptory


CHEMBL:

- Bioactivity data for target CHEMBL219 (D(4) dopamine receptor) - Ki
- Bioactivity data for target CHEMBL217 (D(2) dopamine receptor) - Ki



Dokowanie molekularne


Dokowanie molekularne to metoda modelowania molekularnego służąca do przewidywania najbardziej korzystnej strukturalnie i energetycznie pozycji ligandu w miejscu wiązania celu biologicznego.



**Wynik dokowania liganda
CHEMBL156896 do receptora D2**

Fingerprinty interakcji


- Fingerprints interakcji to wektorowa reprezentacja kontaktów między białkiem a ligandem, w której każdy element wektora opisuje obecność lub typ określonego oddziaływania w kompleksie.
- W ProLIF uwzględnia się oddziaływania hydrofobowe, wiązania wodorowe (donor i akceptor), oddziaływanie $\pi - \pi$, anionowe, kationowe, oddziaływanie kation- π , - kation, van der Waals.



Analiza statystyczna D2

TOP 20 reszt według częstości oddziaływań D2


- Na osi X wykresu przedstawione są reszty aminokwasowe, a na osi Y widoczny jest odsetek ligandów aktywnych / nieaktywnych z danej grupy, które utworzyły przynajmniej jedno oddziaływanie z daną resztą.
- Ligandy aktywne (niebieskie) to ligandy o wysokim powinowactwie do receptora.



Czemu w TOP20 reszt znajdują się takie, które mają więcej ligandów nieaktywnych, niż aktywnych?


Regresja logistyczna D2

- Krzywa ta dostarcza informacji, jak dobrze model radzi sobie z odróżnianiem ligandów aktywnych od nieaktywnych.
- AUC (area under curve) ma tutaj wartość 0.626 ± 0.015 .
- Oznacza to, że model radzi sobie lepiej od modelu losowego ($AUC = 0.5$), ale jego skuteczność nie jest też wysoka ($AUC_{max} = 1$).



Regresja logistyczna D2


- Dodatnia wartość przy reszcie aminokwasowej (kolor niebieski) oznacza, że jeśli ligand utworzy kontakt z tą resztą, to zwiększa się prawdopodobieństwo sklasyfikowania go jako aktywny.



Analiza statystyczna D4

TOP 20 reszt według częstości oddziaływań D4


- Na osi X wykresu przedstawione są reszty aminokwasowe, a na osi Y widoczny jest odsetek ligandów aktywnych / nieaktywnych z danej grupy, które utworzyły przynajmniej jedno oddziaływanie z daną resztą.
- Ligandy aktywne (niebieskie) to ligandy o wysokim powinowactwie do receptora.



Czemu w TOP20 reszt znajdują się takie, które mają więcej ligandów nieaktywnych, niż aktywnych?


Regresja logistyczna D4

- Krzywa ta dostarcza informacji, jak dobrze model radzi sobie z odróżnianiem ligandów aktywnych od nieaktywnych.
- AUC (area under curve) ma tutaj wartość 0.667 ± 0.027 .
- Oznacza to, że model daje minimalnie lepsze wyniki dla receptora D4, jednak niepewność pomiarowa jest dla niego prawie 2x większa



Regresja logistyczna D4

- Dodatnia wartość przy reszcie aminokwasowej (kolor niebieski) oznacza, że jeśli ligand utworzy kontakt z tą resztą, to zwiększa się prawdopodobieństwo sklasyfikowania go jako aktywny.




Uczenie maszynowe

Model i metryki


- **Model:** Random Forest (300 drzew, `class_weight="balanced"`), podział 80/20 ze stratyfikacją.
- **Metryki:** ROC-AUC, PR-AUC, balanced accuracy, MCC, G-mean oraz sensitivity/specificity.

Receptor D2 — wyniki



Zbiór **zbalansowany** (609 akt. / 614 nieakt.). ROC-AUC = 0.715, balanced accuracy = 0.644 — model rozpoznaje obie klasy podobnie dobrze.

Receptor D4 — wyniki



Zbiór **niezbalansowany** (207 akt. / 96 nieakt.). ROC-AUC = 0.712, ale specificity tylko 0.354 przy sensitivity 0.889 — model faworyzuje klasę większościową (Active).

Porównanie D2 vs D4

Metryka	D2 (zbalans.)	D4 (niezbalans.)
ROC-AUC	0.715	0.712
PR-AUC	0.695	0.808
Accuracy	0.644	0.719
Balanced accuracy	0.644	0.622
MCC	0.289	0.289
Sensitivity (TPR)	0.658	0.889
Specificity (TNR)	0.630	0.354
G-mean	0.644	0.561
Brier score	0.217	0.187
Test (Akt./Nieakt.)	609/614	207/96


Pulapka accuracy: D4 ma wyższą accuracy (0.72 vs 0.64), lecz niższe balanced accuracy i G-mean — w ujęciu zrównoważonym radzi sobie *gorzej*. Mimo balanced model przesunięty ku klasie większościowej.

Wnioski

- Fingerprinty z dokowania niosa **realny, lecz umiarkowany** sygnał predykcyjny ($\text{ROC-AUC} \approx 0.71\text{--}0.72$; $\text{MCC} \approx 0.29$) — przydatny do *wstępnego rankingu / wzbogacania*.
- **Niezbalansowanie** (D4) degraduje rozpoznanie klasy mniejszosciowej; `class_weight="balanced"` pomaga, ale nie usuwa obciążenia.
- **Dobór metryk kluczowy:** accuracy myli — licza się balanced accuracy, G-mean, MCC oraz para sensitivity–specificity.



Interpretowalność

Hipoteza 1 - Podczas cross-validacji istotnymi będą te same aminokwasy dla każdego folda





Jaccard index = 0.9 - dla każdego z 5 foldów istotnymi będą prawie te same aminokwasy



Hipoteza 2 - Porównanie różnych metod wyjaśnialności





Hipoteza 2 - Porównanie różnych metod wyjaśnialności




Hipoteza 2 - Porównanie różnych metod wyjaśnialności



Hipoteza 3 - Porównanie metod wyjaśnialności z analizą statystyczną



Hipoteza 4 - Porównanie kluczowych aminokwasów w sekwencji spokrewnionych receptorów



Użyliśmy numeracji Ballesterosa-Weinsteina. Wśród top-15 aminokwasów wspólnymi dla obu białek okazały się 3

Dziękujemy za uwagę!
